

Новый контрольный PDF для проверки гибридного извлечения сущностей

Этот PDF создан как новый тестовый документ для проверки гибридного пайплайна извлечения знаний. В тексте намеренно использованы новые сущности, которых не было в предыдущих документах, чтобы проверить, сможет ли система расширять графовую базу знаний без полного ручного обновления словаря. Документ посвящён современным моделям искусственного интеллекта, задачам обработки текста, методам адаптации и инфраструктуре развёртывания. Формулировки сделаны максимально явными, чтобы парсеру было проще выделять сущности и строить отношения между ними.

Новые языковые модели

Mistral является моделью Transformer и применяется для Text Generation, Summarization и Question Answering. В инженерных обзорах Mistral часто реализуется в vLLM и PyTorch. Mistral использует Instruction Tuning при адаптации к прикладным сценариям. В ряде материалов Mistral также связывают с Concept Context Window, потому что размер контекстного окна влияет на качество работы языковой модели. Для системы извлечения знаний важно, чтобы Mistral был распознан как новая Model, vLLM - как Framework, Instruction Tuning - как Method, а Context Window - как Concept.

Mixtral является моделью Transformer и используется для Text Generation и Summarization. Mixtral использует Mixture of Experts как ключевой Method. В производственных сценариях Mixtral реализуется в PyTorch и vLLM. Кроме того, Mixtral связан с Concept Sparse Routing, потому что в архитектуре mixture-of-experts маршрутизация токенов играет важную роль. Если парсер работает устойчиво, то он должен корректно извлечь новые сущности Mixtral, Mixture of Experts, Sparse Routing и vLLM без ручного добавления каждой из них в seed-граф.

Qwen является моделью Transformer и применяется для Question Answering и Retrieval-Augmented Generation. Qwen использует Instruction Tuning и Quantization. В ряде практических примеров Qwen реализуется в ONNX Runtime и PyTorch. Qwen также связан с Concept Vector Index, потому что в сценариях Retrieval-Augmented Generation важную роль играет индексирование эмбеддингов. Для графовой базы знаний полезно, чтобы Retrieval-Augmented Generation было распознано как Task, Quantization - как Method, ONNX Runtime - как Framework, а Vector Index - как Concept.

Мультимодальные и визуальные модели

CLIP является моделью Neural Network и используется для Image Retrieval и Zero-Shot Classification. CLIP использует Contrastive Learning и часто реализуется в PyTorch. В статьях по мультимодальному обучению CLIP связан с Concept Joint Embedding Space, поскольку изображения и тексты проецируются в общее пространство представлений. Если система

корректно извлекает знания, она должна распознать CLIP как новую Model, Contrastive Learning как Method, Image Retrieval и Zero-Shot Classification как Task, а Joint Embedding Space как Concept.

SAM является моделью Neural Network и применяется для Image Segmentation. SAM использует Prompt Encoding и может быть реализован в PyTorch. Кроме того, SAM связан с Concept Mask Representation, потому что сегментационные модели формируют представление объекта в виде маски. Этот пример нужен для того, чтобы проверить, умеет ли парсер извлекать не только языковые модели, но и современные модели компьютерного зрения с новыми методами и концептами.

Связи между концептами

В документе также присутствуют отношения между концептами и методами. Sparse Routing связано с Mixture of Experts, потому что маршрутизация определяет, какие эксперты активируются на конкретном входе. Joint Embedding Space связано с Contrastive Learning, так как контрастивное обучение формирует согласованное пространство признаков. Vector Index связано с Retrieval-Augmented Generation, поскольку retrieval-сценарий опирается на поиск по векторам. Context Window связано с Instruction Tuning только косвенно, поэтому такая связь не должна автоматически появляться в графе без явного текстового маркера.

Цель контрольного теста

С практической точки зрения этот файл полезен как контрольный тест на действительно новые сущности. В отличие от предыдущего русского PDF, здесь специально собраны названия, которые могут отсутствовать в словаре начальной версии системы. Если после прогона в Neo4j появятся узлы Mistral, Mixtral, Qwen, CLIP, SAM, vLLM, ONNX Runtime, Mixture of Experts, Contrastive Learning, Prompt Encoding, Vector Index и Joint Embedding Space, то это будет означать, что система уже способна не только распознавать заранее известные термины, но и частично расширять базу знаний за счёт гибридного извлечения.